

گزارش مطالعه هفته سوم

بهینه سازی و استقرار مدل در تولید (Model Optimization and Deployment)

نام و نام خانوادگی:

محمد حسین صدیقی

سامان زارع

مهیار قاسمی

دستیار آموزشی:

حانیه خاکشور

درس: مباحث ویژه (پردازش زبان طبیعی)

نیمسال دوم 1405-1404

فهرست مطالب

۳	۱	مقدمه
۳	۱.۱	منابع مطالعه شده در این هفته
۳	۲.۱	هدف مطالعه
۴	۲	مفاهیم کلیدی از کتاب AI and Q Learning Machine
۴	۱.۲	فصل ۲۲: آموزش بدون حافظه (Stateless) در مقابل آموزش با حافظه (Stateful)
۴	۲.۲	مفاهیم تکمیلی
۵	۳	استقرار مدل با FastAPI
۵	۱.۳	آشنایی با FastAPI
۵	۲.۳	مفاهیم اصلی در FastAPI
۶	۴	کانتینری سازی با Docker
۶	۱.۴	مفاهیم پایه Docker
۶	۲.۴	مزایای استفاده از Docker
۶	۳.۴	اجزای اصلی Docker
۶	۴.۴	دستورات مهم Docker
۷	۵	تکنیک های بهینه سازی سرعت استنتاج
۷	۱.۵	پردازش دسته ای (Batching)
۷	۲.۵	برداری سازی (Vectorization)
۷	۳.۵	کوانتیزاسیون (Quantization)
۹	۶	جمع بندی و نتیجه گیری
۹	۱.۶	خلاصه آموخته ها
۹	۲.۶	کاربردهای عملی
۹	۳.۶	تقدیر و تشکر

فصل ۱ مقدمه

۱.۱ منابع مطالعه شده در هفته سوم

بر اساس برنامه پروژه MLOps ارائه شده در فایل MLOps.pdf، در هفته سوم تمرکز بر روی استقرار مدل در محیط تولید و بهینه‌سازی سرعت بوده است. منابع مطالعه شده توسط اعضای گروه عبارتند از:

- فصل ۲۲ کتاب Machine Learning Q and AI: این فصل به تکنیک‌های افزایش سرعت استنتاج مدل‌های یادگیری ماشین می‌پردازد.
- مستندات رسمی FastAPI: برای یادگیری ساخت API‌های کارآمد و مستندسازی خودکار.
- مستندات رسمی Docker: برای آشنایی با کانتینری‌سازی و مفاهیم پایه آن.
- ویدئوها و مقالات آموزشی پیرامون تکنیک‌های Batching، Vectorization و Quantization که در فصل ۲۲ کتاب به آن‌ها اشاره شده است.

۲.۱ هدف مطالعه

هدف از مطالعه این منابع، کسب دانش نظری و عملی لازم برای استقرار مدل‌های یادگیری ماشین در محیط تولید و بهینه‌سازی آن‌ها از نظر سرعت، حافظه و قابلیت اطمینان بود. در این گزارش، خلاصه‌ای از مهم‌ترین مفاهیم آموخته شده ارائه می‌گردد.

استعاره هفته سوم

در توضیحات پروژه آمده است: «حالا تیم شما مانند مدیر یک پست سریع است که باید سفارش‌ها را سریع و بدون اشتباه تحویل دهد؛ اگر مدل کند باشد، مشتری صبر نمی‌کند.» این دقیقاً همان چیزی است که در این هفته آموختیم: چگونه یک مدل را سریع و کارآمد به مشتری برسانیم.

فصل ۲ مفاهیم کلیدی از فصل ۲۲ کتاب AI and Q Learning Machine

۱.۲ معرفی فصل

فصل ۲۲ کتاب Machine Learning Q and AI به بررسی چالش‌های سرعت در مدل‌های بزرگ و راهکارهای عملی برای افزایش سرعت استنتاج (Inference) می‌پردازد. این فصل سه سطح بهینه‌سازی را معرفی می‌کند:

۱.۱.۲ سطح اول: بهینه‌سازی نرم‌افزاری با Batching و Vectorization

Batching (پردازش دسته‌ای) : به جای ارسال یک نمونه به مدل، چندین نمونه را به صورت همزمان ارسال می‌کنیم. این کار باعث می‌شود از قابلیت موازی‌سازی سخت‌افزار (مانند GPU) بهره ببریم و سرشار انتقال داده کاهش یابد. در متن کتاب، مثال واضحی از پردازش دسته‌ای برای ترجمه ماشینی و تحلیل احساسات آورده شده است.

Vectorization (بردارسازی) : تبدیل عملیات‌های حلقه‌ای به عملیات ماتریسی و برداری. کتابخانه‌هایی مانند NumPy و PyTorch این عملیات را به صورت بهینه در سطح C پیاده‌سازی کرده‌اند. بردارسازی به ویژه در مرحله پیش‌پردازش و توکن‌سازی بسیار مؤثر است.

۲.۱.۲ سطح دوم: بهینه‌سازی حافظه و محاسبات با Quantization

Quantization (کوانتیزاسیون) فرآیند کاهش دقت اعداد اعشاری (مثلاً از 32-bit به 8-bit) است. این کار باعث می‌شود:

- حجم مدل حدود 75% کاهش یابد.
 - سرعت استنتاج به شدت افزایش یابد (چون عملیات روی اعداد صحیح سریع‌تر است).
 - مصرف حافظه کاهش یابد.
- کتاب هشدار می‌دهد که کوانتیزاسیون ممکن است باعث افت جزئی دقت (معمولاً کمتر از 1%) شود، بنابراین باید این افت را در مقابل بهبود سرعت سنجید.

۳.۱.۲ سطح سوم: تکنیک‌های پیشرفته

در این سطح به تکنیک‌هایی مانند Pruning (حذف وزن‌های کم‌اهمیت) و Knowledge Distillation (آموزش یک مدل کوچک برای تقلید از مدل بزرگ) اشاره شده است. این تکنیک‌ها پیچیده‌تر هستند و در صورت نیاز می‌توان از آن‌ها استفاده کرد.

۲.۲ نکات عملی از کتاب

- اندازه‌گیری baseline: قبل از هرگونه بهینه‌سازی، باید زمان و حافظه مصرفی مدل اصلی را ثبت کرد.
- آزمایش تدریجی: ابتدا پردازش دسته‌ای را فعال کنید و بهبود را اندازه بگیرید، سپس کوانتیزاسیون را اعمال کنید.
- ثبت نتایج: نتایج هر تکنیک باید در جدولی مقایسه شود تا میزان بهبود سرعت و کاهش حجم مدل مشخص گردد.

فصل ۳ استقرار مدل با FastAPI (مطالعه مستندات)

۱.۳ آشنایی با FastAPI

FastAPI یک فریمورک مدرن و پرسرعت برای ساخت API با زبان پایتون است. اعضای گروه با مطالعه مستندات رسمی، با ویژگی‌های کلیدی زیر آشنا شدند:

- سرعت بسیار بالا: عملکردی قابل مقایسه با Node.js و Go به دلیل استفاده از ASGI (سرور ناهمگام).
- مستندسازی خودکار: تولید خودکار مستندات Swagger و Redoc بر اساس نوع‌دهی (Type Hints) پایتون.
- اعتبارسنجی خودکار داده‌ها: با استفاده از مدل‌های Pydantic، داده‌های ورودی به طور خودکار بررسی می‌شوند.
- پشتیبانی از برنامه‌نویسی ناهمگام (Async): امکان مدیریت همزمان هزاران درخواست بدون .

۲.۳ مفاهیم اصلی در FastAPI

- Endpoint : مسیری‌های URL که هر کدام عملیات خاصی را انجام می‌دهند (مانند /predict).
- Path Parameter و Query Parameter : روش‌های دریافت داده از مسیر یا پارامترهای جستجو.
- Request Body : داده‌هایی که در بدنه درخواست POST ارسال می‌شوند (معمولاً به صورت JSON).
- Response Model : تعیین ساختار داده‌ای که سرویس برمی‌گرداند.
- Dependency Injection : مکانیزمی برای به اشتراک گذاری منطق مشترک بین اندپوینت‌ها (مانند بررسی احراز هویت).

۳.۳ نکات مهم از مستندات

- استفاده از Type Hints باعث می‌شود ویرایشگرها و IDEها تکمیل خودکار و تشخیص خطا را بهتر انجام دهند.
- برای بهبود امنیت، همیشه ورودی‌ها را اعتبارسنجی کنید و از مدل‌های Pydantic استفاده کنید.

- برای بارگذاری مدل‌های سنگین (مانند مدل‌های یادگیری عمیق) از رویداد startup استفاده کنید تا مدل فقط یک بار بارگذاری شود.

فصل ۴ کانتینری سازی با Docker (مطالعه مستندات)

۱.۴ مفاهیم پایه Docker

Docker یک پلتفرم متن باز برای خودکارسازی استقرار برنامه ها درون کانتینرها است. کانتینرها محیط های ایزوله و سبکی هستند که برنامه را به همراه تمام وابستگی هایش می کنند. اعضای گروه با مطالعه مستندات Docker، مفاهیم زیر را فرا گرفتند:

- Image: یک قالب فقط خواندنی شامل دستورالعمل های ساخت کانتینر.
- Container: یک نمونه اجرایی از یک Image.
- Dockerfile: یک فایل متنی شامل دستورات ساخت Image.
- Docker Hub: مخزن عمومی برای به اشتراک گذاری Image ها.

۲.۴ مزایای استفاده از Docker

- قابلیت حمل (Portability): اجرای یکسان بر روی ویندوز، لینوکس و مک.
- تکرارپذیری (Reproducibility): حذف مشکل معروف «روی دستگاه من کار می کند».
- ایزوله سازی: جداسازی وابستگی های برنامه از سیستم میزبان.
- مقیاس پذیری: امکان اجرای چندین نمونه از سرویس به راحتی با Docker Compose یا Kubernetes.

۳.۴ مفاهیم پیشرفته تر مطالعه شده

- لایه بندی (Layering): هر دستور در Dockerfile یک لایه جدید ایجاد می کند. دستوراتی که به ندرت تغییر می کنند (مانند نصب وابستگی ها) باید در ابتدا قرار گیرند تا cache مؤثر باشد.
- شبکه سازی در Docker: آشنایی با شبکه های پیش فرض (bridge, host, none) و نحوه اتصال کانتینرها به یکدیگر.
- حجم ها (Volumes): مکانیزم ذخیره سازی داده ها به گونه ای که پس از حذف کانتینر از بین نروند.

فصل ۵ تکنیک‌های بهینه‌سازی (بر اساس ویدئوها و مقالات)

۱.۵ بررسی دقیق Batching

در ویدئوها و مقالات مطالعه شده، مزایا و معایب Batching به صورت عملی توضیح داده شده است:

- **مزیت اصلی:** افزایش throughput (تعداد نمونه پردازش شده در ثانیه). به عنوان مثال، با دسته ۳۲ تایی، throughput می‌تواند تا ۵ برابر افزایش یابد.
- **معایب:** تأخیر (latency) اولین نمونه در دسته افزایش می‌یابد (زیرا باید منتظر تکمیل دسته بماند). همچنین مصرف حافظه با افزایش اندازه دسته بیشتر می‌شود.
- **نکته کلیدی:** اندازه دسته بهینه باید با آزمون و خطا و با توجه به معماری مدل و سخت‌افزار تعیین شود.

۲.۵ بررسی دقیق Vectorization

بررداری‌سازی یکی از اصول اساسی در کتابخانه‌های محاسباتی مدرن است. در مقالات مطالعه شده، توضیح داده شده که:

- NumPy و PyTorch عملیات برداری شده را با استفاده از BLAS و LAPACK (کتابخانه‌های بهینه ریاضی) پیاده‌سازی می‌کنند.
- حتی روی CPU، عملیات برداری شده می‌تواند ده‌ها برابر سریع‌تر از حلقه‌های پایتون باشد.
- در پردازش زبان طبیعی، توکن‌سازی دسته‌ای و محاسبه همزمان ماتریس‌های وزن از مهم‌ترین کاربردهای برداری‌سازی هستند.

۳.۵ بررسی دقیق Quantization

کوانتیزاسیون یکی از داغ‌ترین موضوعات بهینه‌سازی مدل است. مطالب مطالعه شده شامل موارد زیر بود:

- **انواع کوانتیزاسیون:**
- **Post-Training Quantization:** بدون نیاز به بازآموزی، مستقیماً روی مدل آموزش دیده اعمال می‌شود.

- Quantization-Aware Training (QAT): در حین آموزش، اثر کوانتیزاسیون شبیه‌سازی می‌شود تا افت دقت به حداقل برسد.

- چالش‌ها: برخی لایه‌ها (مانند LayerNorm و Softmax) با کوانتیزاسیون پویا سازگار نیستند و باید در دقت بالاتر باقی بمانند.

- نتایج عملی: کاهش حجم مدل تا 75% و افزایش سرعت تا 3-4 برابر با افت دقت کمتر از 1%.

فصل ۶ جمع‌بندی و نتیجه‌گیری

۱.۶ خلاصه آموخته‌ها

در هفته سوم، اعضای گروه با مفاهیم زیر آشنا شدند:

۱. بهینه‌سازی سرعت استنتاج: آشنایی با سه سطح بهینه‌سازی (نرم‌افزاری، حافظه، معماری) و جزئیات Batching، Vectorization و Quantization از فصل ۲۲ کتاب Machine Learning Q and AI.
۲. استقرار با FastAPI: یادگیری نحوه ساخت API‌های سریع با مستندسازی خودکار، اعتبارسنجی خودکار و پشتیبانی از برنامه‌نویسی ناهمگام.
۳. کانتینری‌سازی با Docker: درک مفاهیم Image، Container، Dockerfile و مزایای استفاده از کانتینرها برای قابلیت حمل و تکرارپذیری.

۲.۶ ارتباط با پروژه MLOps

این دانش دقیقاً متناسب با مرحله سوم پروژه MLOps است: «مدل شما را وارد production می‌کند. FastAPI با REST API استخراج شده و داخل یک Docker container قرار می‌گیرد.» همچنین تکنیک‌های بهینه‌سازی برای افزایش سرعت و کاهش حجم مدل، پاسخگوی نیاز به «پاسخگویی سریع و بدون اشتباه» هستند.

۳.۶ تقدیر و تشکر

از استاد محترم درس، سرکار خانم دکتر مهدیه قاسمی و دستیار آموزشی، خانم حانیه خاکشور که با راهنمایی‌های ارزشمند خود ما را در مسیر یادگیری یاری نمودند، صمیمانه سپاسگزاریم.